

UNIVERSIDADE FEDERAL DE CAMPINA GRANDE
CENTRO DE ENGENHARIA ELÉTRICA E INFORMÁTICA
COORDENAÇÃO DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

PROPOSTA DE DISSERTAÇÃO DE MESTRADO

**RECOMENDAÇÕES MUSICAIS BASEADAS EM TIPOS DE
NOVIDADE**

MESTRANDO

ANDRYW MARQUES RAMOS

ORIENTADOR

NAZARENO FERREIRA DE ANDRADE

CAMPINA GRANDE
DEZEMBRO - 2012

Conteúdo

| | | |
|----------|--|-----------|
| 1 | Introdução | 1 |
| 2 | Objetivo da Proposta | 3 |
| 3 | Revisão da Literatura | 4 |
| 4 | Relevância da Proposta | 7 |
| 5 | Metodologia de Trabalho | 8 |
| 5.1 | Estudos para definição de tipos | 8 |
| 5.1.1 | Dados do Last.fm | 8 |
| 5.1.2 | Dados do 8tracks | 9 |
| 5.1.3 | Dados do survey | 9 |
| 5.2 | Escolha de melhor forma de recomendação para cada tipo | 9 |
| 5.3 | Avaliação | 10 |
| 6 | Cronograma | 11 |

1 Introdução

Sistemas de recomendação auxiliam indivíduos a identificarem de forma mais eficaz itens (livros, músicas, filmes) de interesse a partir de um conjunto potencialmente grande de escolhas [1]. Estes sistemas são importantes tanto para usuários, que terão contato com itens de forma mais rápida, quanto para os disponibilizadores/vendedores dos itens, que terão maior número de acesso e mais renda. Assim, sites como Amazon¹ e Netflix² utilizam recomendadores para aumentar tanto sua receita como a experiência do usuário com o site.

Cada sistema de recomendação possui peculiaridades. Porém, a maior parte dos algoritmos utilizados é baseada na semelhança e popularidade de usuários e objetos. Essa abordagem aumenta a acurácia do algoritmo, pois é provável que o usuário goste das recomendações. No entanto, ela dá pouca ênfase a um tipo de item relevante, o que usuários são improváveis de encontrar por si próprios. O usuário muitas vezes quer variar seu interesse, precisando de itens pouco populares ou itens diferentes dos que ele normalmente consome [2]. Com isso, surge a necessidade de recomendação de itens com novidade, e qualidade, para o usuário.

Itens com novidade (novelty em inglês) são aqueles que o usuário não conhece mas eventualmente pode vir a gostar. Há um trade-off relacionado com a recomendação de itens com novidade e a recomendação de itens com qualidade, que são os que o usuário gostou. Apesar de poder expandir o perfil do usuário, itens com novidade podem nem sempre lhe agradar [3]. Com isso, há a necessidade de um maior entendimento na área de novidade de itens, para que estes itens sejam recomendados com qualidade.

Alguns trabalhos [4,5] relacionam itens com novidade com itens pouco populares. Estes trabalhos se baseiam no fato de que quanto mais popular for um item, maior a probabilidade desse item já ser conhecido pelo usuário. Neste quesito surge o fenômeno Cauda Longa (Long Tail) [6–9], onde poucos itens possuem muitos acessos / vendas (cabeça ou head), considerados itens populares, e muitos itens possuem poucos acessos (cauda ou tail). Estes trabalhos apontam a importância da recomendação de itens da Cauda Longa (pouco populares) para usuários, com o intuito de apresentar novidade e aumentar a satisfação do mesmo.

A necessidade de itens com novidade está particularmente presente na área de recomen-

¹www.amazon.com

²www.netflix.com

dação musical. Tomando como exemplo o seguinte caso: "se você gosta de Beatles provavelmente você gostará de X". Usando os algoritmos de recomendação dos serviços de música mais populares da internet, este X está relacionado a algum outro álbum de Beatles ou de algum integrante da banda [4]. Esta informação vai estar acurada, pois provavelmente o usuário gostará do conteúdo, porém ela não será útil, pois é provável que o usuário já conheça o álbum. Assim, é justificada a importância da investigação de modelos de algoritmos que recomendem músicas com novidade e qualidade. Já foram desenvolvidos alguns modelos que tratam estes aspectos [2, 5, 10].

Apesar da existência destes modelos, eles consideram apenas um tipo de novidade. Porém, podem existir vários tipos de novidade musical. Por exemplo, determinado usuário pode ser habituado a escutar músicas de determinados gêneros e preferir novidade em músicas desconhecidas (Cauda Longa) de gêneros que ele não conhece. Outro usuário pode preferir novidade em músicas desconhecidas de gêneros que ele já conheça. Assim, há a necessidade de identificar diferentes tipos de novidade a partir do perfil do usuário, e a partir destes tipos, realizar recomendações de novidade.

2 **Objetivo da Proposta**

O objetivo principal deste trabalho é aumentar a qualidade de recomendações musicais a partir da definição de tipos de novidade. Foram elencados os seguintes objetivos específicos:

1. Estudar comportamentos e preferências do usuário em relação à novidade de músicas.
2. Identificar tipos de novidade. Os tipos que serão investigados estão relacionados com gêneros musicais e a popularidade dos itens (músicas ou artistas) escutados pelo usuário.
3. Investigar técnicas de recomendação que melhor se adequem a cada tipo de novidade.

3 Revisão da Literatura

Um dos trabalhos mais citados sobre definição de novidade de itens foi conduzido por Herlocker et. al [3]. Neste artigo, os autores avaliam sistemas de recomendação baseados em filtragem colaborativa, que é uma técnica para predição automática de itens (filtragem) sobre algum interesse do usuário a partir de preferências de vários usuários (colaborativa). Neste contexto, eles definem itens com novidade como itens que são desconhecidos pelo usuário mas que possam interessá-lo e argumentam que isto é importante para sistema de recomendação. Muitos recomendadores só estão preocupados com acurácia, que é recomendar itens que provavelmente o usuário goste. Porém nem sempre essas recomendações são úteis, como foi apontado na Seção 1 o caso dos Beatles.

Mcnee et. al [11] reforçam a ideia de que apenas acurácia não é suficiente para sistemas de recomendação. Tanto a novidade quanto a serendipidade (definida como a recomendação não esperada pelo usuário) são importantes para um bom recomendador. Além disso, é posto que os usuários podem ter diferentes expectativas ao utilizar um recomendador. Em determinado momento ele pode querer recomendações mais usuais, em outro recomendações não-usuais. Ainda nesse âmbito do porquê e quando o usuário querer itens com novidade, An et. al [12] apontam que isso depende principalmente de 3 fatores: convicções do usuário, seu estado emocional e seu contexto social.

Como visto, há uma motivação para o estudo na novidade de itens. Porém, há um desafio para a construção de recomendadores que utilizem esse conceito sem diminuir a qualidade das recomendações. Alguns algoritmos tentam fazer isso definindo classes / tipos e recomendando itens diversificados em relação a classes / tipos já vistos pelo usuário. Ziegler et. al [2] utilizam este conceito de diversificação de tópicos, onde itens são adicionados na lista de recomendação quanto mais forem de tópicos diferentes dos já presentes nesta lista.

Nakatsuji et. al [10] propõe um algoritmo baseado na taxonomia dos itens para encontrar recomendações com novidade. Os itens são agrupados em classes. Quanto mais classes de itens vistos usuários compartilharem, mais similares são. Assim, o algoritmo percorre um grafo, onde os nós são usuários, recomendando itens de usuários menos similares.

Outras formas de recomendação de itens com novidade são vistos na literatura. Onuma et. al [13] propõe um método que identifica itens com novidade como itens que são aces-

sados por usuários similares ao usuário alvo mas que também são acessados por usuários não similares a ele. O algoritmo dá notas altas a nós que são bem conectados a escolhas antigas do usuário, e que ao mesmo tempo são bem conectados com itens não relacionados ao usuário.

Zhang et. al [5] apresenta 3 algoritmos. O primeiro é baseado na técnica de Latent Dirichlet Allocation (LDA). No modelo, artistas são tratados como documentos e usuários que os escutam como palavras. Cada artista possui então uma distribuição de ouvintes. A partir da coocorrência de usuários nos diversos artistas é criada a noção de tópico. No caso, um tópico representa comunidades de usuários, clusterizados a partir de preferências similares. A similaridade entre dois itens é dada pela similaridade entre essas distribuições dos tópicos em cada item. O segundo algoritmo prioriza artistas com comunidades de usuários mais diversas. Já o terceiro algoritmo prioriza artistas fora do cluster de artistas do usuário. É utilizada uma forma híbrida destes algoritmos no trabalho.

Apesar do avanço na pesquisa da novidade de itens, é necessário um estudo sobre os diferentes tipos de novidade. Nos trabalhos anteriores a novidade foi definida de forma uniforme. É muito provável que existam tipos diferentes de novidades e que usuários em determinados momentos prefiram um a outro. Além disso, os trabalhos utilizam muito conceitos de tópicos e de grafos baseados em filtragem colaborativa. Porém, itens musicais podem ser comparados a partir de seu conteúdo, comparando-se timbre, ritmo e outras propriedades [14–18]. Essa característica pode auxiliar na qualidade de recomendação de itens com novidade [4].

Além da recomendação, é importante a definição de métricas para medir aspectos relacionados com a novidade de itens. Vargas et. al [19] apresentam um framework formal para a definição de métricas de novidade e diversidade. Os autores identificaram 3 conceitos na área de novidade e diversificação: escolha (usuário seleciona um item), descoberta (usuário é apresentado ao item) e relevância (usuário gosta do item), derivando as métricas a partir destes conceitos.

Celma et. al [4] propõem dois métodos para avaliação da qualidade de recomendações com novidade: um centrado no item e um centrado no usuário. O primeiro estuda a rede de itens com um objetivo de encontrar alguma patologia que esconda itens com novidade. O segundo tem o objetivo de medir a qualidade das recomendações a partir das opiniões dos usuários. Isso é importante, pois é impossível avaliar a qualidade e satisfação do usuário

sem ter um feedback do mesmo [11]. Zhang et. al [5], além de proporem o recomendador detalhado anteriormente, apresentam métricas relacionadas com acurácia, diversidade e novidade, e fazem uma avaliação com o usuário.

4 Relevância da Proposta

No contexto musical, o estudo sobre os tipos de novidade, a recomendação a partir desses tipos e o aumento de qualidade nestas recomendações podem causar os seguintes impactos:

1. Aumento no entendimento sobre música em geral.
2. O aumento da satisfação do usuário do recomendador, por causa de recomendações de qualidade.
3. O aumento do conhecimento do usuário em relação a itens musicais, por causa da recomendação de novidade.
4. O aumento da utilização e da renda de provedores de itens musicais.
5. O estudo sobre tipos de novidade de música, onde alguns conceitos podem ser aproveitados para tipos de novidades em outros itens.

5 Metodologia de Trabalho

Serão seguidos três grandes passos: estudos para definição dos tipos de novidade, escolha da melhor forma de recomendação para cada tipo de novidade e avaliação das técnicas escolhidas.

5.1 Estudos para definição de tipos

A definição de tipos de novidade será estudada a partir de dois conjuntos de dados: dados provenientes de redes sociais musicas (Last.FM³ e 8tracks⁴) e dados provenientes de um survey.

5.1.1 Dados do Last.fm

O Last.fm é uma rede social musical que tem como funções contabilizar as músicas escutadas pelos usuários (processo chamado de scrobbling), permitir a descoberta de usuários com gostos parecidos ao seu, visualizar as músicas escutadas por outros usuários, recomendação de músicas, entre outras. O Last.fm permite o acesso dos dados por uma API.

Assim, serão coletados os seguintes dados:

1. Lista com os artistas mais escutados (e o número de execuções) de cada usuário desde a sua entrada no Last.fm, nos últimos 12 meses, 6 meses, 3 meses e 1 mês (opções de tempo fornecidas pela API).
2. Número total de execuções de cada artista, com o intuito de saber sua popularidade
3. Informações referentes aos artistas, principalmente relacionadas com tags. Tags são palavras que descrevem um item. O Last.FM permite que o usuário marque um artista com tags, como gênero musical (pop, rock, rap), humor (relaxante, depressiva).

Como temos um histórico do usuário e informações relacionadas aos itens escutados (popularidade e gênero), poderemos determinar o perfil do mesmo e verificar se um item novo foi relevante.

³www.lastfm.com

⁴www.8tracks.com

5.1.2 Dados do 8tracks

O 8tracks é uma rede social musical que permite aos usuários criar e escutar playlists (conjunto de músicas para um propósito [20]), além de marcá-las como favoritas. Os dados do 8tracks foram disponibilizados por Remi Gabbilet, CTO e co-fundador do site. Temos acesso às playlists criadas pelos usuários, como também o nome das músicas das mesmas. Iremos investigar então padrões de inserção de novidade nas playlists. Exemplificando: um usuário tem hábito de, nas suas playlists, escolher músicas de Heavy Metal e quebrar esta sequência com Música Clássica. A inserção de Música Clássica, mudando o contraste do conjunto de músicas, representa a novidade.

Apesar do contexto ser diferente, pois a investigação do Last.fm é relacionada ao histórico e a do 8tracks à mudança em um conjunto definido de músicas (playlist), vamos comparar os resultados encontrados nos dois estudos. O objetivo disso é mostrar que os tipos de novidade se adequam ou não a contextos diferentes.

5.1.3 Dados do survey

Com o survey serão realizadas entrevistas semi-estruturadas relacionadas com o gosto musical, perfil musical e novidade musical, com o intuito de se aprofundar no entendimento dos tipos de novidades definidos nos dados.

5.2 Escolha de melhor forma de recomendação para cada tipo

Após esse estudo inicial, serão definidos quais tipos de novidade musical são relevantes à recomendação de itens. A partir desta etapa serão estudadas técnicas de recomendação que melhor se ajustem a cada tipo de novidade, para assim melhorar a qualidade das recomendações.

Estas técnicas podem ser baseadas em filtragem colaborativa, baseadas no conteúdo (onde as recomendações são baseadas na similaridade entre aspectos acústicos, como timbre e ritmo), baseadas no contexto (onde as recomendações são baseadas na similaridade entre informações contextuais, como as descritas em tags), ou formas híbridas.

5.3 Avaliação

Por fim, será realizado um experimento com pessoas para validar o algoritmo. Primeiramente serão feitas perguntas para traçar os perfis dos sujeitos. Então, a partir desses perfis, serão feitas recomendações a partir de quatro recomendadores:

1. Recomendador de itens aleatórios
2. Recomendador da literatura que não dê ênfase a recomendações com novidade.
3. Recomendador de novidade da literatura
4. Recomendador proposto

Cada usuário receberá itens dos recomendadores acima, sem saber qual. Ele terá a opção de indicar se gostou do item e se o item é familiar ou desconhecido. O objetivo dessa validação é mostrar que o recomendador proposto recomenda itens com novidade e qualidade, baseado nas métricas apontadas na literatura (as métricas serão estudadas e selecionadas posteriormente).

A tabela 1 mostra as atividades planejadas.

Tabela 1: Atividades planejadas.

| Atividade | Descrição |
|-----------|--|
| 1 | Realizar uma pesquisa bibliográfica sobre as soluções existentes para o problema de <i>novidade de itens</i> |
| 2 | Elaborar relatório contendo a avaliação das soluções encontradas |
| 3 | Coletar dados do Last.FM |
| 4 | Criar survey e disponibilizá-lo online |
| 5 | Fazer análise dos dados |
| 5.1 | Fazer análise dados Last.FM |
| 5.2 | Fazer análise dados 8tracks |
| 5.3 | Fazer análise do survey |
| 6 | Definir tipos de novidade |
| 7 | Elaborar um artigo para ISMIR'2013 |
| 8 | Aprofundar estudos sobre tipos de recomendação musical |
| 9 | Encontrar melhor forma de recomendação para cada tipo |
| 10 | Implementar algoritmos |
| 11 | Realizar experimentos |
| 12 | Avaliar resultados dos experimentos |
| 13 | Escrever a dissertação de mestrado |
| 14 | Elaborar um artigo para ISMIR'2014 |
| 15 | Defender a dissertação de mestrado |

6 Cronograma

Segue na Tabela 2 o cronograma referente às atividades da Seção 5.

Tabela 2: Cronograma do projeto de pesquisa.

| | | Atividade | | | | | | | | | | | | | | | | | |
|------|-----|-----------|---|---|---|---|-----|-----|-----|---|---|---|---|----|----|----|----|----|----|
| Ano | Mês | 1 | 2 | 3 | 4 | 5 | 5.1 | 5.2 | 5.3 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 |
| 2012 | Ago | X | | | | | | | | | | | | | | | | | |
| 2012 | Set | X | | | | | | | | | | | | | | | | | |
| 2012 | Out | X | | | | | | | | | | | | | | | | | |
| 2012 | Nov | X | | | | | | | | | | | | | | | | | |
| 2012 | Dez | | X | | | | | | | | | | | | | | | | |
| 2013 | Jan | | X | X | | | | | | | | | | | | | | | |
| 2013 | Fev | | | | X | X | X | X | | X | | | | | | | | | |
| 2013 | Mar | | | | | X | X | X | X | X | X | | | | | | | | |
| 2013 | Abr | | | | | X | | | X | X | X | | | | | | | | |
| 2013 | Mai | | | | X | | | | X | | | | | | | | | | |
| 2013 | Jun | | | | | | | | | | | X | X | | | | | | |
| 2013 | Jul | | | | | | | | | | | X | X | | | | | | |
| 2013 | Ago | | | | | | | | | | | X | X | | | | | | |
| 2013 | Set | | | | | | | | | | | | | X | | | | | |
| 2013 | Out | | | | | | | | | | | | | X | | | | | |
| 2013 | Nov | | | | | | | | | | | | | | X | X | X | | |
| 2013 | Dez | | | | | | | | | | | | | | X | X | X | | |
| 2014 | Jan | | | | | | | | | | | | | | X | X | X | | |
| 2014 | Fev | | | | | | | | | | | | | | | | X | X | |
| 2014 | Mar | | | | | | | | | | | | | | | | | X | X |

Referências

- [1] P. Resnick and H. R. Varian, “Recommender systems,” *Commun. ACM*, vol. 40, no. 3, pp. 56–58, Mar. 1997. [Online]. Available: <http://doi.acm.org/10.1145/245108.245121>
- [2] C.-N. Ziegler, S. M. McNee, J. A. Konstan, and G. Lausen, “Improving

- recommendation lists through topic diversification,” in *Proceedings of the 14th international conference on World Wide Web*, ser. WWW '05. New York, NY, USA: ACM, 2005, pp. 22–32. [Online]. Available: <http://doi.acm.org/10.1145/1060745.1060754>
- [3] J. L. Herlocker, J. A. Konstan, L. G. Terveen, and J. T. Riedl, “Evaluating collaborative filtering recommender systems,” *ACM Trans. Inf. Syst.*, vol. 22, no. 1, pp. 5–53, Jan. 2004. [Online]. Available: <http://doi.acm.org/10.1145/963770.963772>
- [4] O. Celma and P. Herrera, “A new approach to evaluating novel recommendations,” in *Proceedings of the 2008 ACM conference on Recommender systems*, ser. RecSys '08. New York, NY, USA: ACM, 2008, pp. 179–186. [Online]. Available: <http://doi.acm.org/10.1145/1454008.1454038>
- [5] Y. C. Zhang, D. O. Séaghdha, D. Quercia, and T. Jambor, “Auralist: introducing serendipity into music recommendation,” in *Proceedings of the fifth ACM international conference on Web search and data mining*, ser. WSDM '12. New York, NY, USA: ACM, 2012, pp. 13–22. [Online]. Available: <http://doi.acm.org/10.1145/2124295.2124300>
- [6] Erik, “From niches to riches: Anatomy of the long tail,” *MIT Sloan Management Review*, vol. 47, no. 4, pp. 67+. [Online]. Available: <http://proquest.umi.com/pqdlink?did=1143181091&Fmt=7&clientId=49682&RQT=309&VName=PQD>
- [7] C. Anderson, *The Long Tail: Why the Future of Business Is Selling Less of More*. Hyperion, 2006.
- [8] S. Goel, A. Broder, E. Gabrilovich, and B. Pang, “Anatomy of the long tail: ordinary people with extraordinary tastes,” in *Proceedings of the third ACM international conference on Web search and data mining*, ser. WSDM '10. New York, NY, USA: ACM, 2010, pp. 201–210. [Online]. Available: <http://doi.acm.org/10.1145/1718487.1718513>

- [9] O. Celma, *Music Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space*, 1st ed. Springer Publishing Company, Incorporated, 2010.
- [10] M. Nakatsuji, Y. Fujiwara, A. Tanaka, T. Uchiyama, K. Fujimura, and T. Ishida, “Classical music for rock fans?: novel recommendations for expanding user interests,” in *Proceedings of the 19th ACM international conference on Information and knowledge management*, ser. CIKM '10. New York, NY, USA: ACM, 2010, pp. 949–958. [Online]. Available: <http://doi.acm.org/10.1145/1871437.1871558>
- [11] S. M. McNee, J. Riedl, and J. A. Konstan, “Being accurate is not enough: how accuracy metrics have hurt recommender systems,” in *CHI '06 Extended Abstracts on Human Factors in Computing Systems*, ser. CHI EA '06. New York, NY, USA: ACM, 2006, pp. 1097–1101. [Online]. Available: <http://doi.acm.org/10.1145/1125451.1125659>
- [12] J. An, D. Quercia, and J. Crowcroft, “This paper won’t change your mind, but...: Why individuals seek diverse opinions (or why they don’t),” *Technical Report of the University of Cambridge*, 2012.
- [13] K. Onuma, H. Tong, and C. Faloutsos, “Tangent: a novel, ‘surprise me’, recommendation algorithm,” in *Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining*, ser. KDD '09. New York, NY, USA: ACM, 2009, pp. 657–666. [Online]. Available: <http://doi.acm.org/10.1145/1557019.1557093>
- [14] D. Bogdanov and P. Herrera, “How much metadata do we need in music recommendation? a subjective evaluation using preference sets,” in *International Society for Music Information Retrieval Conference (ISMIR)*, 2011.
- [15] E. Pampalk and M. Gasser, “An implementation of a simple playlist generator based on audio similarity measures and user feedback,” in *International Society for Music Information Retrieval Conference (ISMIR)*, 2006, pp. 389–390.

- [16] F. Maillet, D. Eck, G. Desjardins, and P. Lamere, “Steerable playlist generation by learning song similarity from radio station playlists,” in *International Society for Music Information Retrieval Conference (ISMIR)*, 2009, pp. 345–350.
- [17] D. Bogdanov, J. Serrà, N. Wack, P. Herrera, and X. Serra, “Unifying low-level and high-level music similarity measures,” *IEEE Transactions on Multimedia*, vol. 13, pp. 687–701, 08/2011 2011.
- [18] P. Cano, M. Koppenberger, and N. Wack, “Content-based music audio recommendation,” in *Proceedings of the 13th annual ACM international conference on Multimedia*, ser. MULTIMEDIA ’05. New York, NY, USA: ACM, 2005, pp. 211–212. [Online]. Available: <http://doi.acm.org/10.1145/1101149.1101181>
- [19] S. Vargas and P. Castells, “Rank and relevance in novelty and diversity metrics for recommender systems,” in *Proceedings of the fifth ACM conference on Recommender systems*, ser. RecSys ’11. New York, NY, USA: ACM, 2011, pp. 109–116. [Online]. Available: <http://doi.acm.org/10.1145/2043932.2043955>
- [20] S. J. Cunningham, D. Bainbridge, and A. Falconer, “‘more of an art than a science’: Supporting the creation of playlists and mixes,” in *International Society for Music Information Retrieval Conference (ISMIR)*, *PAGES* =.